Báo cáo triển khai Thành viên 2

Tối ưu Chatbot, Lệnh ghi và Phân loại (9Router & Local Router) — ứng dụng Finmi

Ngày 07/11/2026 · Người thực hiện: Thành viên 2 (TV2) · Mã nguồn gốc: nhánh `main` @ `69bc60a` (đã pull 98 commit mới nhất) · Trạng thái: hoàn thành code, chưa commit/deploy

3 → 0–1	−43,6%	10 / 10	473 / 473
Lượt gọi LLM tối đa / câu hỏi chat (B0 → B1)	Độ dài system prompt chat (3.177 → 1.791 ký tự)	Câu gợi ý nhanh được trả lời local, 0 lượt LLM	Test Flutter pass · analyze 0 lỗi

1. Tóm tắt

TV2 phụ trách cụm AI dùng 9Router (chat, lệnh ghi) và bước phân loại danh mục. Mục tiêu là cắt số lượt gọi LLM từ tối đa 3 lượt/câu xuống 0–1 lượt, để chat phản hồi gần như tức thì và tiết kiệm hạn mức gói 9Router. Cả 4 đầu việc được giao (H3, H2+H4, H5, H8) đã được triển khai; mỗi đầu việc nằm sau một feature flag riêng để TV4 chạy đối chứng Trước (B0 – cờ OFF) và Sau (B1 – cờ ON) trên cùng bộ dữ liệu.

Mã	Việc	Kết quả chính	Cờ
H3	Định tuyến local, 0 lượt LLM	Câu tra cứu chuẩn (chi/thu tháng, ngân sách, công nợ, danh mục, so sánh, dự báo, định kỳ, bất thường, hóa đơn gần đây, giả định tiết kiệm) trả lời thẳng từ SQLite.	`ai.chat.local_router`
H2	Bỏ lượt assistant_command thừa	Câu hỏi chỉ-đọc không còn đi qua bước diễn giải lệnh.	`ai.chat.skip_command`
H4	Gộp 2 lượt chat thành 1	Đoán tool theo từ khóa, đọc FACTS local trước, gửi kèm ngay lượt chat đầu (tắt tool-call).	`ai.chat.prefetch_facts`
H5	Rút gọn system prompt	Prompt ngắn hơn 43,6%, phần tĩnh đặt đầu, FACTS/QUESTION cuối, thêm max_tokens = 800.	`ai.chat.compact_prompt`
H8	Phân loại merchant chạy local	merchant-rules-v1 chạy trên app, bỏ lời gọi mạng classify; bỏ từ khóa đơn âm tiết gây bắt nhầm.	`ai.classify.local`

2. Hiện trạng trước tối ưu (B0)

Luồng cũ trong `chat_screen.dart` khi dịch vụ lệnh đã cấu hình — mọi câu, kể cả câu hỏi tra cứu đơn giản, đều đi qua chuỗi tuần tự sau:

Bước	Action gọi server	Vai trò	Lượt LLM
1	`assistant_command`	Diễn giải câu nhập thành lệnh (ghi/sửa/xóa) hoặc kind = query	1
2	`chat` (allowToolCalls = true)	LLM chọn tool đọc dữ liệu (get_expense_summary…)	1
3	`chat` (kèm FACTS)	LLM trả lời dựa trên FACTS do app đọc local	1
Tổng		Câu hỏi tra cứu thông thường	**3**

- Phân loại hóa đơn: khi chưa xác định được danh mục, `import_coordinator.dart` gọi mạng action `classify` — vốn chỉ là luật từ khóa tĩnh trên server nhưng vẫn tốn 1 round-trip và 1 đơn vị quota.
- Bộ phân loại dòng hàng dùng `text.contains` với từ khóa đơn âm tiết (`ca, mi, cu, qua, vo, but`), nên bắt nhầm “card”, “mini”, “quà tặng”, “voucher”, “button”, “cục sạc”…
- System prompt của answerChat có 20 dòng chỉ dẫn, nhiều quy tắc bảo mật/từ chối bị nhắc lại 2–3 lần.

3. Các phương pháp đã triển khai

3.1 H3 — Định tuyến local trả lời 0 lượt LLM

Bộ luật thuần Dart `ChatRoutingRules.localIntent` nhận diện 11 ý định tra cứu chuẩn. `tryAnswerLocally` gọi `LocalChatAssistant` (hoặc bộ đọc công nợ mới) với thời hạn 2 giây; nếu nhận diện không chắc chắn, đọc dữ liệu lỗi/quá hạn, hoặc câu trả lời local không có dữ liệu, ứng dụng tự động quay về đường cloud — người dùng không bao giờ nhận câu trả lời rỗng.

- Chủ động **không** trả lời local với: câu phân tích ("tại sao", "gợi ý", "có nên", "làm sao"…), câu ghép hai ý ("thu và chi…"), câu chênh lệch thu chi, câu có động từ ghi hoặc số tiền, câu tiếng Anh, và khi đang có lệnh/bản nháp chờ.
- Thêm câu trả lời công nợ local `localDebtAnswer`: phân biệt "tôi nợ ai" / "ai nợ tôi", chỉ tính khoản còn mở, không bao giờ đưa số điện thoại hay ghi chú vào câu trả lời.
- Sửa `_isComparisonQuestion`: "Tháng trước tôi chi bao nhiêu?" giờ trả đúng tổng chi tháng trước (trước đây bị trả lời bằng câu so sánh).

3.2 H2 + H4 — Cắt assistant_command thừa và gộp 2 lượt chat thành 1

H2: `ChatRoutingRules.isReadOnlyQuestion` chỉ cho phép bỏ qua assistant_command khi câu có dấu hiệu nghi vấn *và* không có bất kỳ dấu hiệu ghi nào (ghi, thêm, tạo, lưu, xóa, sửa, cho vay, trả nợ, góp quỹ, đặt ngân sách, nhắc, hủy…) *và* không chứa số tiền. Thiết kế thiên về an toàn: nghi ngờ thì vẫn đi luồng cũ.
H4: `ChatRoutingRules.guessTools` đoán tối đa 2 tool và kỳ dữ liệu (current / YYYY-MM từ "tháng trước", "tháng 8/2026"). `prefetchChatFacts` đọc FACTS local rồi `_answerWithLlm` gửi một lượt `chat` duy nhất với `allowToolCalls = false`. Nếu không đoán được tool hoặc đọc lỗi, giữ nguyên luồng 2 lượt cũ.

3.3 H5 — Rút gọn System Prompt của answerChat

Prompt được tách sang `supabase/functions/_shared/chat_prompt.ts` với hai phiên bản: **legacy** (giữ nguyên từng chữ để đo B0) và **compact**. Client gửi `promptVersion: "compact"` khi cờ bật; server kiểm tra giá trị hợp lệ.

- Gộp các quy tắc lặp thành 6 khối: danh tính, PHẠM VI, AN TOÀN, DỮ LIỆU, KHÓA FACTS, VĂN PHONG.
- Phần tĩnh đặt đầu (thuận lợi cho prompt caching phía nhà cung cấp); chế độ tool, FACTS, QUESTION đặt cuối.
- Thêm `max_tokens = 800` cho bản compact; log server ghi thêm `promptChars` và `maxTokens` để đối chiếu M8.

3.4 H8 — Đưa phân loại merchant-rules-v1 về chạy trên app

- `MerchantCategoryClassifier` port nguyên thứ tự và từ khóa của server; cải thiện thêm: chuẩn hóa `đ → d` (trên server NFD không tách chữ đ, nên "Điện lực" chưa bao giờ khớp "dien luc").
- `ImportCoordinator` dùng bộ phân loại local khi cờ bật; khi tắt vẫn gọi `classify` như cũ (phục vụ B0).
- Bộ phân loại dòng hàng: bỏ ca, mi, cu, qua, vo, but; thay bằng cụm nhiều âm tiết (cá hồi, cà phê, hoa quả, trái cây, mì tôm, mì gói, củ cải, tập vở, bút bi…) và so khớp theo nguyên từ.

4. Luồng xử lý sau tối ưu (B1)

Loại câu nhập	Đường đi	Lượt LLM B0	Lượt LLM B1
Câu tra cứu chuẩn (VD: "Tháng này tôi đã chi bao nhiêu?")	H3: SQLite trên máy	3	**0**
Câu hỏi phân tích (VD: "Chênh lệch thu chi tháng này?", "Tại sao tháng này chi nhiều?")	H2 bỏ command → H4 một lượt chat kèm FACTS	3	**1**
Câu hỏi không đoán được tool	H2 bỏ command → luồng tool-call cũ	3	2
Lệnh ghi (VD: "Nam nợ tôi 500k")	assistant_command (không đổi)	1	1
Lệnh ghi bị server hiểu là query	assistant_command → H4 một lượt chat	3	2
Danh tính / ngoài phạm vi	Trả lời cố định trên máy	0	0
Phân loại merchant khi nhập hóa đơn	H8: luật local	1 lượt mạng	**0**

Số lượt trong bảng là số lượt theo thiết kế, đếm trực tiếp từ code. Số liệu thực tế trên bộ 40 câu sẽ do TV4 đo (mục 6).

5. Feature flags và migration

Migration `20261107100000_tv2_chat_ai_flags.sql` thêm 5 cờ cho cả 3 môi trường (dev, staging, production), mặc định `enabled = true`. Ràng buộc tên cờ đổi từ danh sách cố định sang pattern `^[a-z][a-z0-9_.]{1,63}$`, để TV1/TV3 thêm cờ mới không phải viết lại ràng buộc (tránh xung đột migration giữa các thành viên).

Cờ	Mã	Tác dụng khi ON	Khi OFF (B0)
`ai.chat.local_router`	H3	Trả lời local câu tra cứu chuẩn	Mọi câu đi cloud
`ai.chat.skip_command`	H2	Câu hỏi chỉ-đọc bỏ assistant_command	Luôn gọi assistant_command
`ai.chat.prefetch_facts`	H4	Một lượt chat kèm FACTS đọc trước	Tool-call 2 lượt
`ai.chat.compact_prompt`	H5	Prompt compact + max_tokens	Prompt legacy
`ai.classify.local`	H8	Phân loại merchant trên máy	Gọi action classify

Đo B0: đặt `enabled = false` cho 5 dòng trên trong bảng `app_feature_flags` của môi trường kiểm thử; đo B1: đặt lại `true`. Ứng dụng tải cờ từ server khi khởi động/đăng nhập (cache `remote.feature_flags.v1` chỉ dùng khi mất mạng), nên sau khi đổi cờ cần khởi động lại app trước khi chạy phép đo.

6. Hệ thống đo lường và số liệu bàn giao cho TV4

Mỗi lượt chat ghi một sự kiện vào `ChatMetricsRecorder` (bộ đệm 500 sự kiện trong bộ nhớ) và in log `finmi_ai_metric {...}`. Sự kiện không chứa nội dung câu hỏi. Ví dụ:

```
finmi_ai_metric {"kind":"chat_turn","route":"local","llm_calls":0,"latency_ms":42,"local_intent":"expens
eTotal","at":"2026-11-07T08:00:00Z"}
```

KPI	Chỉ số	Nguồn số liệu	Số liệu hiện có	Kỳ vọng B1
M6	Lượt LLM trung bình / câu	Trường `llm_calls`	Theo thiết kế: 3 → 0/1/2 (mục 4)	< 0,8 lượt
M7	Tỉ lệ xử lý local	`route = local` + sự kiện `kind = classify`	10/10 câu gợi ý nhanh đi local	35–50%
M8	Prompt token / lượt	usage.prompt_tokens (chờ TV3 – N2); log `promptChars`	−43,6% ký tự prompt tĩnh	−20–30% token
M9	Độ trễ chat p50/p95	Trường `latency_ms` (bấm gửi → hiện trả lời)	Chưa đo trên thiết bị	Local < 100 ms; LLM −45%

> **Lưu ý trung thực về số liệu**
> Các con số trong báo cáo này là số liệu **đo được offline** (độ dài prompt, số lượt theo code, kết quả test). Số liệu B0/B1 thực tế (M6–M9 trên bộ 40 câu, token thật từ 9Router) **chưa có**: cần deploy edge function và migration lên môi trường kiểm thử, và cần TV3 hoàn tất ghi usage token (N2). TV4 điền vào bảng Chương 6 sau khi chạy script đánh giá.

7. Kiểm thử và cổng chất lượng

Bộ kiểm thử	Nội dung	Kết quả
`flutter analyze`	Phân tích tĩnh toàn dự án	0 lỗi
`flutter test` (toàn bộ)	Toàn bộ test của ứng dụng	**473 / 473 pass**
`chat_routing_rules_test.dart`	20 lệnh ghi không bị coi là câu hỏi; 10 câu gợi ý nhanh đi local; câu phân tích đi LLM; đoán tool và kỳ	Pass

Bộ kiểm thử	Nội dung	Kết quả
`chat_screen_test.dart`	H3: 0 lượt LLM; H4: 1 lượt, tắt tool-call; B0 (cờ OFF): 2 lượt; ghi metrics đúng route	Pass
`local_debt_answer_test.dart`	Phân biệt chiều nợ, bỏ khoản đã tất toán, không lộ số điện thoại	Pass
`merchant_category_classifier_test.dart`	Luật merchant; 6 ca bắt nhầm cũ nay không còn; cụm từ mới vẫn phân loại đúng	Pass
`import_coordinator_test.dart`	H8 local không gọi classify; B0 vẫn gọi classify	Pass
`feature_flags_test.dart`	5 cờ mới mặc định ON, tắt được qua bảng cờ	Pass
`assistant_guard_test.ts`	Chống prompt injection, chặn lộ bí mật (bắt buộc với H5)	Pass*
`chat_prompt_test.ts`	Bản compact ngắn hơn ≥ 20%, giữ đủ 11 quy tắc an toàn, phần động nằm cuối, legacy không đổi	Pass*

* Máy phát triển không có Deno; hai bộ test TypeScript được chạy bằng Node 22 với lớp giả lập Deno.test. Nên chạy lại bằng deno test trên CI trước khi merge.

Gate M6 “0 lệnh ghi bị hiểu nhầm thành câu hỏi”: đạt trên bộ 20 lệnh mẫu (tiếng Việt và tiếng Anh, có/không có số tiền). Gate M8 “vượt 100% assistant_guard_test”: đạt.

Ngoài ra đã sửa một test đang fail sẵn trên `main` (`keeps the local loading indicator…`): UI đã đổi spinner thành chữ “Đang suy nghĩ ...” nhưng test chưa được cập nhật.

8. Rủi ro và lưu ý triển khai

Rủi ro / lưu ý	Mức	Xử lý
Client có cờ compact_prompt ON gọi server ai-api cũ sẽ bị từ chối (400, trường promptVersion lạ)	Cao	Deploy edge function ai-api **trước** khi phát hành bản app mới
max_tokens = 800 có thể cắt cụt nếu model 9Router tính cả reasoning token	TB	TV4 theo dõi tỉ lệ JSON hợp lệ ở B1; tăng hằng số COMPACT_CHAT_MAX_TOKENS nếu cần
Đoán tool sai khiến FACTS thiếu, LLM trả lời “chưa đủ dữ liệu”	TB	Luật đoán chỉ kích hoạt khi khớp từ khóa rõ; có thể tắt riêng cờ prefetch_facts
Khi dữ liệu local không tải được, câu tra cứu chờ tối đa 2 giây trước khi chuyển sang cloud	Thấp	Bằng thời hạn fallback hiện có; đọc SQLite thường < 100 ms
Xung đột code với TV1 (import_coordinator.dart – O4) và TV3 (feature_flags, generateNinerRouterJson – N2/N5)	TB	Thay đổi được giữ tối thiểu, chỉ thêm tham số tùy chọn; báo trước cho TV1/TV3
Câu trả lời local chỉ có tiếng Việt	Thấp	Người dùng tiếng Anh vẫn đi cloud như cũ

9. Danh sách file thay đổi

File	+ / −	Ghi chú
`lib/features/chat/domain/chat_routing_rules.dart`	+349	Mới · luật H2, H3, H4
`lib/features/chat/presentation/chat_screen.dart`	+114 / −1	Định tuyến, đếm lượt, metrics
`lib/features/chat/application/chat_metrics.dart`	+92	Mới · M6/M7/M9
`lib/features/chat/domain/local_debt_answer.dart`	+86	Mới · trả lời công nợ local
`lib/features/ingestion/domain/merchant_category_classifier.dart`	+77	Mới · H8
`supabase/functions/_shared/chat_prompt.ts`	+76	Mới · H5
`lib/features/chat/application/local_chat_router.dart`	+74	Mới · H3/H4

File	+ / −	Ghi chú
`lib/core/config/feature_flags.dart`	+47 / −18	5 cờ mới
`lib/features/ingestion/domain/line_category_classifier.dart`	+42 / −25	Bỏ từ khóa ngắn
`supabase/migrations/20261107100000_tv2_chat_ai_flags.sql`	+25	Mới · cờ + ràng buộc
`lib/features/ingestion/application/import_coordinator.dart`	+22	Dùng phân loại local
`supabase/functions/ai-api/index.ts`	+13 / −30	promptVersion, max_tokens
`lib/core/providers/app_providers.dart`, `ai_chat_client.dart`, `local_chat_assistant.dart`	+15 / −3	Nối cờ, sửa so sánh
7 file test (Dart + TypeScript)	+512 / −4	4 file mới, 3 file cập nhật

10. Việc tiếp theo

- Commit lên nhánh riêng và tạo PR; chạy deno test trên CI.
- Deploy edge function ai-api và migration lên môi trường staging.
- Phối hợp TV3: nối usage.prompt_tokens của 9Router vào ai_request_metrics (N2) để có M8 thật; thống nhất cách gom log finmi_ai_metric vào telemetry chung (N3).
- Bàn giao TV4: chạy bộ 40 câu chat/lệnh với 5 cờ OFF (B0) rồi ON (B1), xuất M6–M9 vào bảng Chương 6.
- Hướng phát triển (Chương 7, không làm trong đợt này): cache theo sync cursor (H10), streaming JSON (H11), Gemini Nano (H12).